資料分析實作 HW2

零售需求之多元線性回歸分析

依 CRISP-DM 完成前 20 名特徵選擇、模型評估與 95% 預測區間

學號	7115056075
資料集	Retail Store Inventory and Demand Forecasting
模型	Multiple Linear Regression
完成日期	2026 年 10 月 14 日

選用特徵	MAE	RMSE	R^2
前 20 名	16.55	22.20	0.7768

本報告數值由 7115056075_hw2.ipynb 實際執行產生。

摘要

本研究以 Kaggle 的零售庫存與需求合成資料為分析對象，依 CRISP-DM 流程建立多元線性回歸模型。資料共 76,000 筆、16 欄，扣除日期與目標 Demand 後有 14 個原始候選特徵；類別欄位經 One-Hot Encoding 後形成 44 個模型欄位。本研究先切分訓練集與測試集，再以訓練集擬合前處理與 F-test 特徵選擇器，選取重要性前 20 名特徵。前 20 名模型在 15,200 筆測試資料的 MAE 為 16.55、RMSE 為 22.20、R^2 為 0.7768；95% 預測區間涵蓋率為 95.60%。結果顯示縮減特徵後仍保留接近全部 44 個欄位模型的預測能力，但合成資料、隨機切分與可能的目標資訊重疊限制了實務推論。

1. 資料來源與研究脈絡

資料集名稱：Retail Store Inventory and Demand Forecasting

來源連結：https://www.kaggle.com/datasets/atomicd/retail-store-inventory-and-demand-forecasting

資料涵蓋日期、商店、商品、類別、地區、庫存、銷售量、訂購量、價格、折扣、天氣、促銷、競品價格、季節、疫情與需求。Kaggle 頁面將其標示為合成資料，因此本研究定位為方法展示，而非真實零售企業績效估計。

- 研究問題：能否用多個零售特徵預測 Demand，並量化單筆預測的不確定性？
- 目標變數：Demand。
- 候選原始特徵：14 個；Date 不納入本次橫斷面線性回歸。
- 主要限制：Units Sold 與 Demand 的定義可能接近，模型可用於預測比較，但係數不可直接視為因果效果。

2. CRISP-DM 分析流程

2.1 Business Understanding

需求預測可協助安排補貨與安全庫存。本作業的成功條件是：模型必須優於平均值基準、以可重現方式完成前 20 名特徵選擇，並同時提供點預測、評估指標及 95% 預測區間。

2.2 Data Understanding

- 資料規模：76,000 筆、16 欄。
- 訓練集：60,800 筆；測試集：15,200 筆；random_state = 42。
- 分析先檢查欄位型態、缺失值、重複值與敘述統計。
- 資料為合成資料，適合比較方法，不應直接外推至真實商店。

2.3 Data Preparation

1. 先執行 80/20 train-test split，避免測試資料參與前處理與特徵選擇。
2. 數值欄位以 MinMaxScaler 縮放；類別欄位以 OneHotEncoder(drop='first', handle_unknown='ignore') 轉換。
3. Promotion 與 Epidemic 為二元欄位，直接保留。
4. 前處理器只在訓練集 fit，再分別 transform 訓練集與測試集。

2.4 Modeling 與前 20 名特徵選擇

本研究使用 SelectKBest 搭配 f_regression，以每個編碼後特徵對 Demand 的單變量 F-score 排名，並依使用者指定保留重要性前 20 名。選擇器只以訓練資料擬合。模型包含平均值基準、全部 44 個欄位的 LinearRegression，以及前 20 名欄位的 LinearRegression。

2.5 Evaluation

評估指標包括 MAE、RMSE 與 R^2。另以 statsmodels OLS 在相同前 20 名欄位上估計 95% prediction interval。預測區間描述單一新觀測值可能落入的範圍，因此比平均反應的信賴區間更適合備貨風險溝通。

2.6 Deployment

本次交付可執行 Notebook、指標 JSON、比較 CSV、特徵排名 CSV 與圖表。若要部署至真實環境，應固定欄位格式與前處理流程、監測資料漂移，並改用時間切分重新驗證後才可上線。

3. 模型結果

模型	特徵數	MAE	RMSE	R^2
平均值基準	0	37.04	46.99	-0.0000
全部特徵線性回歸	44	16.27	21.81	0.7845
前 20 名特徵線性回歸	20	16.55	22.20	0.7768

表 1　測試集模型比較（N = 15,200）

全部特徵模型的 R^2 為 0.7845；前 20 名模型為 0.7768，差距約 0.0077。前 20 名模型以較少欄位保留大部分預測能力，符合本作業特徵選擇要求。相較平均值基準，兩個線性回歸模型的 MAE 與 RMSE 均明顯較低。

前 20 名模型的訓練集 OLS R^2 為 0.7701，調整後 R^2 為 0.7701；整體 F 統計量為 10,181.78。這些統計量說明線性組合具有整體解釋力，但不代表因果關係。

4. 前 20 名特徵

排名	特徵	F-score	p-value
1	Units Sold	137,207.43	< 0.001
2	Units Ordered	21,495.85	< 0.001
3	Epidemic	9,303.64	< 0.001
4	Category_Furniture	6,317.22	< 0.001
5	Category_Groceries	5,583.41	< 0.001
6	Promotion	5,197.68	< 0.001
7	Discount	3,177.43	< 0.001
8	Weather Condition_Sunny	1,417.73	< 0.001
9	Inventory Level	972.37	< 0.001
10	Weather Condition_Rainy	700.01	< 0.001
11	Seasonality_Summer	617.22	< 0.001
12	Category_Toys	602.62	< 0.001
13	Product ID_P0020	590.08	< 0.001
14	Weather Condition_Snowy	506.84	< 0.001

排名	特徵	F-score	p-value
15	Seasonality_Spring	380.17	< 0.001
16	Product ID_P0009	311.22	< 0.001
17	Product ID_P0012	265.45	< 0.001
18	Product ID_P0017	207.35	< 0.001
19	Product ID_P0013	184.43	< 0.001
20	Category_Electronics	182.85	< 0.001

表 2　由訓練集選出的前 20 名特徵

Units Sold、Units Ordered 與 Epidemic 的 F-score 居前。F-test 是單變量篩選方法，只衡量單一欄位與目標的線性關聯；它不會自動處理特徵間冗餘，也不能證明業務因果。

5. 預測圖與不確定性

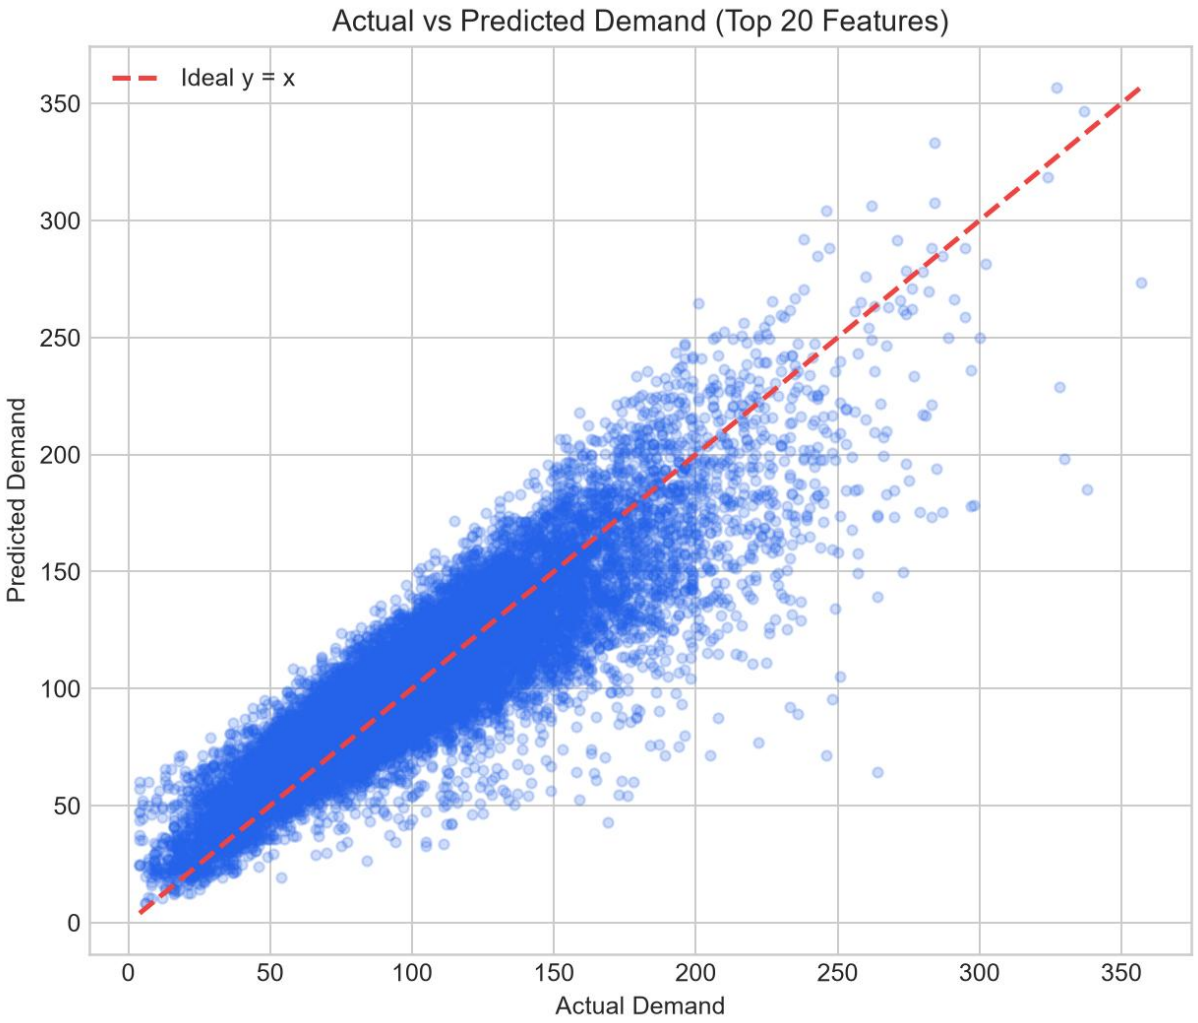


圖 1　測試集實際值與預測值

散點整體沿理想線分布，但高需求區域仍有較大誤差，顯示模型無法完全捕捉極端需求。

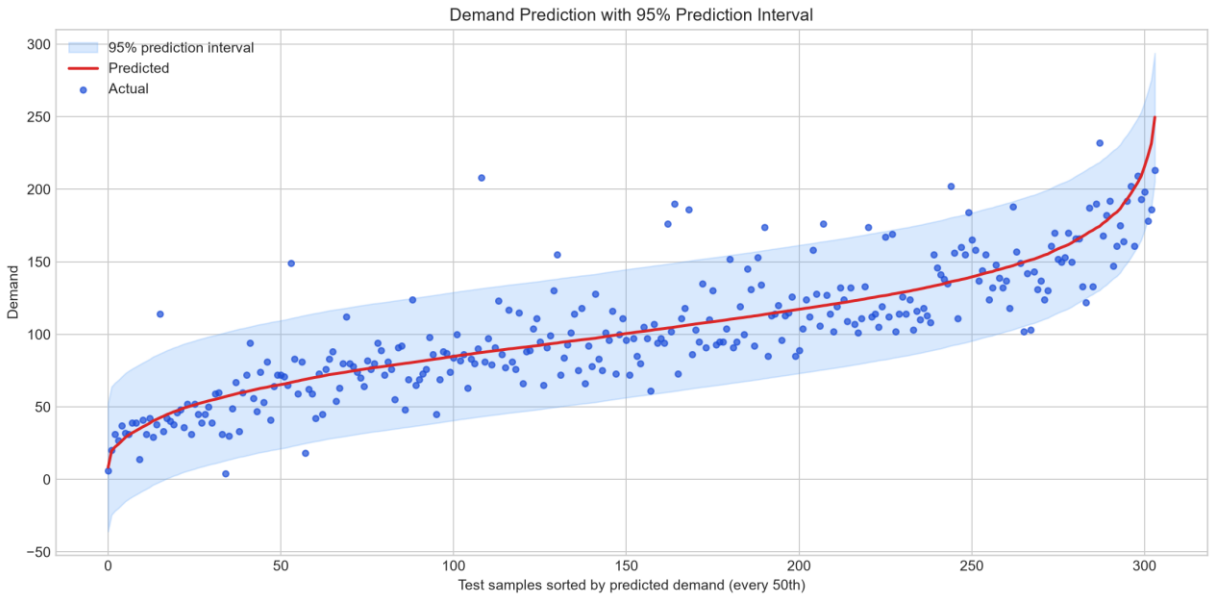


圖 2　測試樣本的 95% 預測區間

測試集 95% 預測區間涵蓋率為 95.60%，平均寬度為 88.28。涵蓋率接近名目 95%，但區間偏寬，使用者不應只依點預測決定庫存。

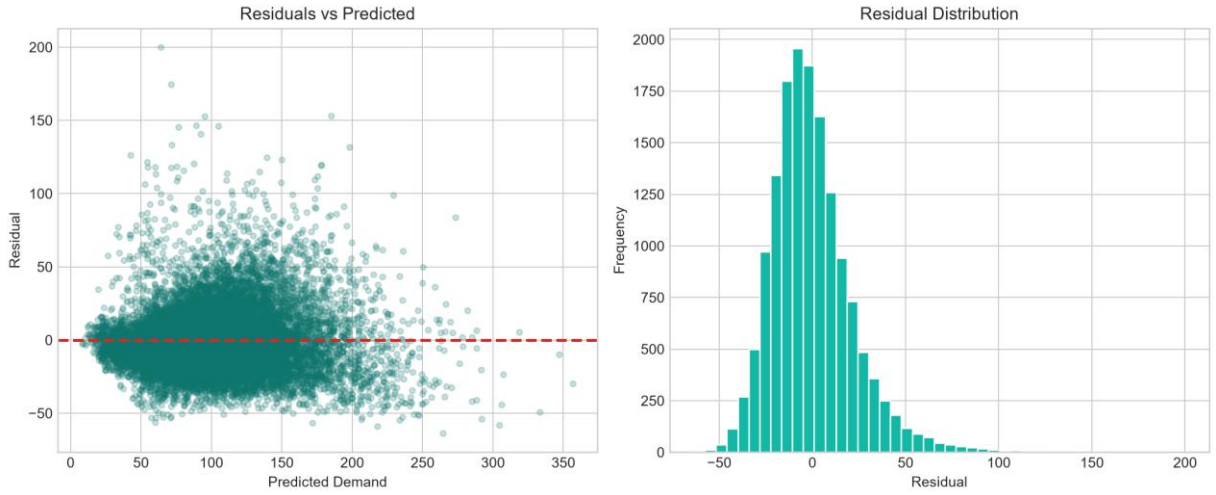


圖 3　殘差診斷

殘差診斷用來檢查系統性偏差與誤差分布；圖形顯示仍存在較大的正負殘差，因此實務應再比較非線性模型與時間序列驗證。

6. GPT 輔助內容

GPT 協助內容包括：整理作業規格與 CRISP-DM 章節、設計資料洩漏防護流程、建立前 20 名 F-score 特徵選擇、產生多元線性回歸與 statsmodels 預測區間程式、同步 README 與報告，以及執行測試和圖表檢查。所有模型分數、特徵排名及圖表皆由 Notebook 實際運算，未由 GPT 捏造。完整對話另附「ChatGPT-需求預測與特徵選擇-20261007-1014.pdf」。

7. NotebookLM 摘要

NotebookLM 研究顯示，零售需求預測通常不只比較單一模型，而會依資料型態選擇線性模型、樹模型或時間序列方法。線性回歸容易解釋各欄位與需求的關聯，可作為清楚的基準；Ridge 可降低高度相關特徵造成的係數不穩定，Lasso 可透過稀疏係數進行內嵌式特徵選擇。若需求與促銷、天氣及商品類別之間存在非線性互動，可再比較梯度提升樹。具有日期順序的零售資料則應採時間切分或滾動驗證，避免隨機切分把未來資訊混入訓練資料。模型評估除了 MAE、RMSE 與 R^2，也應呈現預測區間，讓管理者同時掌握點預測與缺貨風險。這些研究結果支持本作業以多元線性回歸建立可解釋基準，並把正則化、非線性模型及時間驗證列為後續改進方向。

註：本段為使用者提供之 NotebookLM 研究內容的整理；繳交時應一併保留 NotebookLM 來源或操作證明。

8. 主流或更優方法比較

方法	核心概念	可能優點	本研究中的限制
Ridge	L2 正則化	降低共線性造成的係數不穩定	需用交叉驗證選擇正則強度
Lasso	L1 正則化	係數可縮為 0，提供內嵌式選擇	結果受縮放與超參數影響
HistGradientBoosting	樹的加法集成	捕捉非線性與特徵交互作用	解釋性較低，須額外調參
ARIMA / SARIMA	時間相依與季節性	適合按商店與商品預測未來需求	需重整為連續時間序列並採時間切分

表 3　其他主流方法之定性比較

表中方法未在本作業中實際訓練，因此不宣稱其分數優於線性回歸。合理的後續實驗應使用相同切分與指標進行公平比較。

9. 限制與結論

- 合成資料不代表真實商店的資料生成過程與市場衝擊。
- 隨機切分適合本次回歸作業，但零售預測部署應使用時間切分或滾動驗證。
- Units Sold 可能與 Demand 高度重疊，會提高預測分數並限制因果解釋。
- F-test 僅檢查單變量線性關聯；後續可比較 Ridge、Lasso 與非線性樹模型。

結論：前 20 名特徵線性回歸在可解釋性、特徵數量與預測表現間取得合理平衡，測試集 R^2 為 0.7768，95% 預測區間涵蓋率為 95.60%。本結果足以完成課堂上的 CRISP-DM 與多元線性回歸示範；若用於實務決策，仍需真實資料、時間驗證及模型監控。

10. 參考資料

1. Kaggle. Retail Store Inventory and Demand Forecasting. https://www.kaggle.com/datasets/atomicd/retail-store-inventory-and-demand-forecasting

2. scikit-learn. SelectKBest. https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SelectKBest.html

3. scikit-learn. f_regression. https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.f_regression.html

4. scikit-learn. LinearRegression and linear models. https://scikit-learn.org/stable/modules/linear_model.html

5. scikit-learn. HistGradientBoostingRegressor. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html

6. statsmodels. PredictionResults.summary_frame. https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.PredictionResults.summary_frame.html